

Modelagem Box-Jenkins da taxa esperada do Fed na Kalshi

Felipe Carvalho - PPGEco/UFES, Econometria II

2026-09-10

0.1 Hipotese e enquadramento

Kagan & Baiocchi (2026) documentam que os preços da Kalshi se comportam como probabilidades genuínas, e crescentemente conforme a resolução se aproxima: na categoria *Economics*, o escore de Brier cai de forma quase linear de 0,108 (três meses) para 0,066 (fechamento), sobre 16.701 mercados resolvidos. A justificativa que oferecem é a Lei dos Grandes Números, e portanto o teste que executam é **transversal** – reúne 2,24 milhões de mercados e compara frequência realizada com preço declarado. Por construção, esse desenho nada diz sobre a **trajetória** de um mercado individual.

Este trabalho testa em série temporal, num único mercado, uma implicação de preços que se atualizam com a chegada de informação, usando Box-Jenkins. As previsões correspondentes são: a série é $I(1)$, suas diferenças são ruído branco, e nenhum ARIMA supera o passeio aleatório fora da amostra. Os artigos de referência não executam esse teste temporal; a construção da distribuição implícita segue Diercks, Katz & Wright (2026).

Desvio declarado quanto a frequência. A lista indica preferência por séries mensais ou trimestrais. A série aqui é diária: a Kalshi opera desde 2021 e seus mercados de FFR desde 2022, de modo que uma série mensal não alcançaria as 120 observações mínimas; e o fenômeno de interesse – atualização da expectativa com a chegada de informação – é intrinsecamente de alta frequência. O mínimo de 120 observações é cumprido. A série não está disponível em pacote de R ou Python.

0.2 Dados e reproducibilidade


A série foi construída a partir de trades individuais da família KXFED, usando os endpoints histórico e recente da API da Kalshi. O snapshot entregue contém 63.929 trades em 98 mercados. A transformação diária usa o último preço observado no dia, volume agregado e preenchimento forward de dias sem trades. A reunião escolhida é a de maior volume total. A


distribuicao implicita e obtida diferenciando a sobrevivencia dos contratos por strike, apos o ajuste middle-out e a redistribuicao de bins vazios.

observa- coes	inicio	fim	media	desvio_pa- drao	mi- nimo	ma- ximo	media_abs_dife- renca
181	2026-01-30	2026-07-29	3.5065	0.1921	2.8852	3.7117	0.0341

1 Preparacao e inspecao preliminar

1.1 Questao 1





A serie e diaria e cobre 181 observacoes no horizonte metodologico de 180 dias anteriores a reuniao do FOMC. O horizonte ancora na data em que o mercado para de negociar (`close_time`), que e a data da reuniao, e nao na data de liquidacao da Kalshi (`expiration_time`), uma semana posterior; as duas constam da serie.

O grafico em nivel mostra variacao associada a atualizacao das expectativas para a reuniao. A dispersao deve ser lida como funcao do horizonte: ela encolhe a medida que a reuniao se aproxima e resta menos incerteza a resolver, o que a Questao 5 quantifica.

dia_da_semana	nego- cios	contra- tos	dias_no_ca- lendario	dias_com_ne- gocio	nego- cios_por_dia	fim_de_se- mana
segunda	948	576065.9	26	23	36.4615	FALSE
terca	2214	741711.4	26	24	85.1538	FALSE
quarta	1952	540027.5	26	26	75.0769	FALSE
quinta	899	374794.0	25	24	35.9600	FALSE
sexta	1097	797659.1	26	25	42.1923	FALSE
sabado	542	109406.1	26	22	20.8462	TRUE
domingo	698	113132.6	26	23	26.8462	TRUE

A tabela acima mede a atividade por dia da semana e sustenta uma decisao que aparece nas Questoes 2, 3 e 7: o periodo sazonal candidato e $s = 7$, nao $s = 5$. A Kalshi negocia nos sete

dias, e o contrato analisado teve negocios em 22 dos 26 sabados e em 23 dos 26 domingos da amostra. O que distingue o fim de semana nao e a ausencia de negociacao, e sim a espessura do livro: o volume diario cai por um fator de tres a sete. Nenhuma observacao e, portanto, mero carregamento do ultimo preco de sexta-feira, e o calendario relevante tem sete dias.

2 Ordem de integracao

2.1 Questao 2

Os testes ADF, PP e KPSS foram calculados com especificacoes sem constante, com constante e com constante e tendencia. No ADF, o numero maximo de defasagens e 12 e a selecao e feita por AIC; PP e KPSS usam a largura curta de Bartlett. Os p-valores apresentados sao aproximacoes interpoladas entre os valores criticos reportados pelo `urca`, devendo ser interpretados junto com a estatistica e os valores criticos.

series	test	specifi- cation	statis- tic	criti- cal_10	criti- cal_5	criti- cal_1	p_va- lue_ap- prox	lags	lag_se- lection
nivel	ADF	none	2.8909	-2.5800	-	-	0.1000	12	AIC
					1.9500	1.6200			
nivel	ADF	drift	-	-3.4600	-	-	0.0100	12	AIC
			3.6578		2.8800	2.5700			
nivel	ADF	trend	-	-3.9900	-	-	0.1000	12	AIC
			2.1566		3.4300	3.1300			
nivel	PP	constant	-	-3.4677	-	-	0.0485	NA	short
			2.8990		2.8776	2.5752			Bartlett
nivel	PP	trend	-	-4.0117	-	-	0.0100	NA	short
			6.6329		3.4356	3.1416			Bartlett
nivel	KPSS	mu	3.0676	0.3470	0.4630	0.5740	0.1000	NA	short
									Bartlett
nivel	KPSS	tau	0.6408	0.1190	0.1460	0.1760	0.1000	NA	short
									Bartlett
pri- meira__dife- renca	ADF	none	-	-2.5800	-	-	0.0100	12	AIC
			8.3409		1.9500	1.6200			
pri- meira__dife- renca	ADF	drift	-	-3.4600	-	-	0.0100	12	AIC
			7.2553		2.8800	2.5700			
pri- meira__dife- renca	ADF	trend	-	-3.9900	-	-	0.0100	12	AIC
			7.9354		3.4300	3.1300			

series	test	specifi- cation	statis- tic	criti- cal_10	criti- cal_5	criti- cal_1	p_va- lue_ap- prox	lags	lag_se- lection
pri- meira_dife- renca	PP	constant	- 22.3358	-3.4679	- 2.8777	- 2.5753	0.0100	NA	short Bartlett
pri- meira_dife- renca	PP	trend	- 22.3471	-4.0119	- 3.4357	- 3.1416	0.0100	NA	short Bartlett
pri- meira_dife- renca	KPSSmu		0.0474	0.3470	0.4630	0.5740	0.0100	NA	short Bartlett
pri- meira_dife- renca	KPSStau		0.0133	0.1190	0.1460	0.1760	0.0100	NA	short Bartlett

pe- ri- odo_sa- zo-	d	D	nal	justificativa
1	0	7		d = 1 pelos testes de raiz unitaria em nivel e primeira diferenca. D = 0 decidido com evidencia, nao por omissao: o periodo candidato e s = 7 porque a Kalshi negocia nos sete dias (q1_atividade_semanal.csv); nsdiffs sugere D = 0 (OCSB) e D = 0 (Canova-Hansen); a FAC da primeira diferenca nos lags 7, 14, 21 fica dentro da banda de 95% (+/-0.1461); e impor D = 1 piora o AIC e piora o BIC. Ver q2_sazonal.csv.


critério	valor	referencia	conclusao
nsdiffs (OCSB)	0.0000	D sugerido	D = 0
nsdiffs (Canova-Hansen)	0.0000	D sugerido	D = 0
FAC da 1a diferenca no lag 7	0.1152	banda 95%: +/- 0.1461	dentro da banda
FAC da 1a diferenca no lag 14	-0.0003	banda 95%: +/- 0.1461	dentro da banda
FAC da 1a diferenca no lag 21	0.0560	banda 95%: +/- 0.1461	dentro da banda
AIC: D = 0 menos D = 1	-112.0149	negativo favorece D = 0	D = 0
BIC: D = 0 menos D = 1	-111.8959	negativo favorece D = 0	D = 0

A decisao adotada e $d = 1$ e $D = 0$. A primeira diferenca do ponto medio da faixa-alvo e a transformacao usada nas etapas de identificacao.

$D = 0$ e resultado, não omissão. Com $s = 7$ justificado pela atividade de negociação, cinco evidências independentes convergem: os testes de raiz unitária sazonal OCSB e Canova-Hansen indicam $D = 0$; a FAC da primeira diferença fica dentro da banda de 95 por cento nos lags 7, 14 e 21; e impor $D = 1$ piora o AIC e o BIC em cerca de 112 pontos. Diferenciar sazonalmente uma série sem raiz sazonal introduz uma raiz MA não-invertível, exatamente o defeito que a Questão 6 examina.

3 Identificação

3.1 Questão 3



mo- del	pe- ri- odo_sa- zo- nal						justificativa	evidencia
	p	d	q	P	D	Q		
ARIMA(0,1,1)	0	0	0		0	7	Leitura canonica: a FAC corta apos o lag 1 e a FACP decai. E a especificacao que o par de graficos indica primeiro.	FAC significativa nos lags 1, 4, 8; FACP decai ao longo de 1, 2, 3, 5, 6, 8.

mo- del	p	d	q	P	D	Q	pe- ri- odo_sa- zo- nal	justificativa	evidencia
ARIMA(1,1,0)	0	0	0			7		Leitura AR concorrente: o lag 1 da FACP e o maior em modulo; testa se a persistencia se explica por um unico termo autorregressivo.	FACP no lag 1 = -0.3175, fora da banda de 95% (+/-0.1461).
ARIMA(1,1,1)	0	0	0			7		Mistura parcimoniosa: acomoda simultaneamente persistencia e choque quando FAC e FACP nao separam com nitidez.	FAC no lag 1 = -0.3175 e FACP no lag 1 = -0.3175, ambas fora da banda.
ARIMA(3,1,3)	0	0	0			7		Especificacao estendida, incluida para SER TESTADA contra a restricao de admissibilidade da Q4(f): os lags 2, 3, 5, 6 e 8 da FACP sugerem estrutura mais rica, e o AIC tende a premia-la.	FACP fora da banda tambem nos lags 2, 3, 5, 6, 8.

lag	sazonal	FAC	FACP	banda_95	FAC_significativa	FACP_significativa
6	FALSE	-0.0625	-0.2043	0.1461	FALSE	TRUE
7	TRUE	0.1152	-0.0358	0.1461	FALSE	FALSE
8	FALSE	-0.1473	-0.2922	0.1461	TRUE	TRUE
13	FALSE	-0.0043	-0.0715	0.1461	FALSE	FALSE
14	TRUE	-0.0003	-0.0126	0.1461	FALSE	FALSE
15	FALSE	0.0378	0.1298	0.1461	FALSE	FALSE
20	FALSE	0.0148	0.0058	0.1461	FALSE	FALSE
21	TRUE	0.0560	0.0458	0.1461	FALSE	FALSE
22	FALSE	-0.0120	-0.0073	0.1461	FALSE	FALSE

A FAC da primeira diferenca corta abruptamente apos o lag 1, com um coeficiente negativo e forte, enquanto a FACP decai ao longo de varios lags. Esse par de padroes identifica um MA(1); o lag 1 isolado da FACP sustenta a leitura AR(1) concorrente. O coeficiente negativo no primeiro lag e o que a literatura de microestrutura atribui a oscilacao entre pontas de compra e venda, e nao a previsibilidade economica.

Dai os candidatos: ARIMA(0,1,1), a leitura canonica; ARIMA(1,1,0), a leitura autorregressiva; ARIMA(1,1,1), a mistura parcimoniosa. O ARIMA(3,1,3) entra como quarta especificacao, deliberadamente estendida, para ser confrontada com a restricao de admissibilidade da Questao 4 – os lags 2, 3, 5, 6 e 8 da FACP sugerem estrutura mais rica, e e util verificar o que acontece

quando o criterio de informacao a premia. Todos usam a mesma variavel dependente e a mesma amostra efetiva, condicao sem a qual a comparacao por AIC e BIC nao seria valida.

As defasagens sazonais foram inspecionadas explicitamente, com seis ciclos completos no grafico e a tabela acima cobrindo os lags 7, 14 e 21 e suas vizinhancas. Nenhuma fica fora da banda de 95 por cento. Por isso nenhum candidato leva componente sazonal: a ausencia de sazonalidade e uma conclusao apoiada em evidencia.


4 Estimacao e selecao

4.1 Questao 4

					ad- mis- si- vel	
mo- del	coefficients	standard_errors	t_statistics	lo- sigma2k	AIC	BIC
ARIMA(0,1,1)	0.40173117	ma1 0.062014	ma1 -11.79	0.000198	29.2940	- 180 TRUE
					392.5321	391.1961
ARIMA(1,0,0)	0.4346	ar1 0.070509	ar1 -4.458	0.007184	8.4415	- 180 TRUE
					365.6350	350.2971
ARIMA(1,1,1)	0.10249896; ma1 -0.821432	ar1 0.087399; ma1 0.042322	ar1 2.859; ma1 -19.409	0.000222	2.2357	- 180 TRUE
					398.4781	388.8925
ARIMA(3,0,3)	0.32694; ar2 -0.676157; ar3 0.089707; ma1 0.480248; ma2 -0.02901; ma3 -0.802223	ar1 0.090273; ar2 0.108268; ar3 0.089093; ma1 0.055575; ma2 0.064722; ma3 0.057463	ar1 -10.553; ar2 -6.245; ar3 1.007; ma1 8.642; ma2 -0.448; ma3 -13.961	0.000261	1.4166	- 180 FALSE
					408.8381	381.4824

modelo	tipo_raiz	parte_real	parte_imaginaria	modulo	modulo_inverso	admissivel
ARIMA(3,1,3) MA		-0.6413	0.7673	1.0000	1.0000	FALSE
ARIMA(3,1,3) MA		-0.6413	-0.7673	1.0000	1.0000	FALSE

Raizes inversas dos polinomios



mo- delo_se- le- cio- nado	cri- terio	ven- ce- dor_aido- mis- si- vel	ven- ce- dor_aido- mis- si- vel	cri- rios_ ver- gem	ven- ce- tri- cao	ven- ce- tri- cao	aic_ le- o- nado	bic_ le- o- nado	se- n_ cam- di- si- veis	nota	
ARIMA(1,1,1) entre os modelos admissi- veis (Q4f antes de Q4e)	AIC	ARIMA(1,1,1)	ARIMA(1,1,1)	ARIMA(1,1,1)	ARIMA(1,1,1)	ARIMA(1,1,1)	398.4738	398.8925	4	3	AIC e BIC CONCORDAM entre os admissiveis (ARIMA(1,1,1)). Sem a restricao de admissibilidade o AIC escolheria ARIMA(3,1,3).
n_co- efi- ci- mo- delo	tes	sigma2_Conta- ame- k_usado	conta_Conta- verifica- pelcaAIC	aic_re- alpa-aic_re- cu- por- lado	tado	nota					
ARIMA(1,1,3)	TRUE	attr(logLik(fit), 'df') contra length(coef(fit))	-	-	k = 3 para 2 coeficientes: a variancia residual estimada E contabilizada como parametro livre. Toda comparacao AIC/BIC nesta tabela usa a mesma convencao e a mesma amostra efetiva (n = 180), condicao sem a qual os criterios nao sao comparaveis (Q4c).						

Os modelos foram estimados por maxima verossimilhanca sobre a mesma amostra efetiva ($n = 180$ apos a diferenciacao), o que torna AIC e BIC comparaveis entre eles.

Raizes e admissibilidade. A tabela `q4_raizes.csv` traz as duas escalas para evitar a ambiguidade que a convencao costuma criar. A coluna `modulo` e a raiz do polinomio propriamente dita, e a condicao de estacionariedade e de invertibilidade e `modulo > 1`; a coluna `modulo_inverso` e o seu reciproco, para o qual a mesma condicao se le como valor menor que um. A figura desenha as raizes inversas contra o circulo unitario, convencao grafica usual: admissivel e o ponto que cai dentro do circulo.


O ARIMA(3,1,3) tem duas raizes MA de modulo 1,000034. Nao se trata de uma margem apertada, e sim de raizes numericamente sobre o circulo unitario: o otimizador parou na fronteira da regio admissivel, nao dentro dela. O polinomio nao e invertivel e o modelo esta fora de competicao.

Ordem das operacoes. Invertibilidade e estacionariedade sao restricoes de admissibilidade, nao criterios de ajuste. Um modelo que as viola nao e um modelo pior; e um modelo que nao esta no conjunto de escolha. Por isso o filtro se aplica antes do criterio de informacao, e nao como ressalva posterior. Sem a restricao, o AIC elegeria o ARIMA(3,1,3) – o melhor ajuste entre os candidatos e, simultaneamente, o unico inadmissivel. Entre os tres admissiveis, AIC e BIC concordam no ARIMA(1,1,1), que e o modelo levado adiante. A distincao importa: relatar apenas o vencedor do AIC irrestrito produziria um modelo cujas previsoes de longo prazo nao convergem e cuja representacao autorregressiva infinita nao existe.

Convencao de k. A contagem de parametros usada pelos criterios de informacao foi verificada no proprio objeto ajustado, e nao presumida: `attr(logLik(fit), "df")` devolve 3 para um modelo com 2 coeficientes, de modo que a variancia residual estimada conta como parametro livre. O AIC recalculado a mao com essa convencao reproduz exatamente o valor reportado, como registra `q4_convencao_k.csv`.

5 Diagnostico

5.1 Questao 5



teste	estatistica	graus_liberdade	p_valor
Ljung-Box	19.2227	12	0.0833
Jarque-Bera	10702.2608	2	0.0000
ARCH-LM	22.0694	7	0.0025

medida	valor
Inclinacao de $\log(\text{dif}^2)$ sobre dias ate a reuniao	0.0224
Erro-padroao da inclinacao	0.0038
Estatistica t da inclinacao	5.8906
p-valor da inclinacao	0.0000
Variancia da 1a metade	0.0165
Variancia da 2a metade	0.0003

medida	valor
Razao de variancias (1a / 2a)	55.6340
Estatistica F	55.6340
p-valor do teste F	0.0000
ARCH-LM (para contraste)	22.0694
p-valor do ARCH-LM (para contraste)	0.0025

mo- del	coefficients	standard_er- rors	t_statistics	lo- sigma2	AIC	BIC	nobs	AIC_vs_se- lecio- nado	me- hora_AIC
ARIMA(1,1,2)	ar1 0.44215; ar2 -0.087524; ma1 -0.79826	ar1 0.088995; ar2 0.08146; ma1 0.052542	ar1 2.744; ar2 -1.074; ma1 -15.193	0.0062	202.8030-	-	180	0.8653	FALSE
					397.6060	-398.48342			
ARIMA(1,1,2)	ar1 0.55169; ma1 -0.61252; ma2 -0.16231	ar1 0.243715; ma1 0.234278; ma2 0.175326	ar1 0.226; ma1 -2.614; ma2 -0.926	0.0062	202.5879-	-	180	1.2956	FALSE
					397.1758	-398.4040			

mo- delo	etapa	motivo	evidencia	ques- tao
ARIMA(3,1,3)	admissi- bilidade	polinomio MA nao-invertivel	raizes MA com modulo (limiar 1 + 0.001)	Q4(f)
ARIMA(2,5,e)	sobreajuste deliberado	termo extra nao melhora o ajuste	AIC -397.6060 contra -398.4714 do ARIMA(1,1,1) (diferenca +0.8653); admissivel: TRUE	Q5(e)
ARIMA(2,5,e)	sobreajuste deliberado	termo extra nao melhora o ajuste	AIC -397.1758 contra -398.4714 do ARIMA(1,1,1) (diferenca +1.2956); admissivel: TRUE	Q5(e)

O Ljung-Box foi calculado no lag 14 com correcao pelos graus de liberdade do modelo e nao rejeita a ausencia de autocorrelacao residual. O Jarque-Bera rejeita a normalidade com folga, resultado esperado numa serie cujas variacoes se concentram em poucos dias de noticia.

Heterocedasticidade: dois fenomenos distintos. O ARCH-LM testa agrupamento de volatilidade, isto e, variancia alta seguida de variancia alta. Nao e o que caracteriza esta serie. A dispersao aqui cai porque o horizonte encurta: a cada dia que passa, resta menos incerteza a ser resolvida ate a reuniao. Isso e uma tendencia deterministica na variancia, e um teste desenhado para agrupamento pode nao detecta-la ainda que ela seja grande.

Por isso o ARCH-LM aparece acompanhado de duas medidas diretas. A regressao de $\log(\text{diferenca ao quadrado})$ sobre os dias que faltam para a reuniao tem inclinacao positiva

e altamente significativa: quanto mais distante a reuniao, maior a dispersao. E a variancia da primeira metade da amostra supera a da segunda por um fator de 55,6, com o teste F rejeitando a igualdade. Os tres resultados sao complementares, e nao substitutos.


Modelos descartados. A tabela `modelos_descartados.csv` registra o caminho percorrido, e nao apenas o destino: o ARIMA(3,1,3) sai por falha de invertibilidade na Questao 4, e as duas especificacoes de sobreajuste saem por nao melhorarem o ajuste. O sobreajuste deliberado acrescenta um termo AR e um termo MA ao modelo selecionado; como nenhum dos dois reduz o AIC, a especificacao escolhida e adequada nesse sentido.

6 Sobrediferenciacao

6.1 Questao 6

model	coefficients	standard_er- rors	t_statistics	lo- sigma2 glik	AIC	BIC	nobs
selecio- nado	ar1 0.249896; ma1 -0.821432	ar1 0.087399; ma1 0.042322	ar1 2.859; ma1 -19.409	0.0062202.2357	-	-	180
sobredife- renciado	ar1 -0.312059; ma1 -0.999999	ar1 0.070777; ma1 0.014883	ar1 -4.409; ma1 -67.19	0.0076180.6396	-	-	179

parametro_ma	erro_padrao_ma	raiz_modulo
ma1 -0.999999	ma1 0.014883	1



O modelo sobrediferenciado aumenta d em uma unidade, mantendo os demais termos do modelo selecionado. A comparação de variância residual, coeficiente MA e raiz permite avaliar o custo prático de diferenciar em excesso.


7 Previsão fora da amostra

7.1 Questão 7

As últimas 24 observações foram reservadas para validação. O primeiro esquema usa origem fixa e previsão multipassos; o segundo usa origem móvel e previsão de um passo, com os coeficientes mantidos. Os benchmarks são o passeio aleatório e o ingenuo sazonal, este com período $s = 7$ – o período justificado na Questão 1 pela atividade de negociação nos sete dias da semana, e confirmado como sem raiz sazonal na Questão 2.

Figura 1 -- Previsao fora da amostra: ARIMA(1,1,1) contra benchmarks ingenuos

Esquema 1 (origem fixa, 24 passos). Faixa azul: intervalo de previsao de 95%.



Fonte: elaboracao propria a partir de dados da Kalshi (snapshot congelado em data/raw/). Metodo de construcao da distribuicao implicita conforme Diercks, Katz e Wright (2026). Cobertura empirica do intervalo: 100,0% contra 95% nominais -- as densidades preditivas sao largas demais.

scheme	model	RMSE	MAE	MAPE
origem_fixa_24_passos	ARIMA	0.0234	0.0206	0.5612
origem_fixa_24_passos	passeio_aleatorio	0.0282	0.0244	0.6649
origem_fixa_24_passos	sazonal_ingenuo	0.0241	0.0208	0.5677
origem_movel_1_passo	ARIMA	0.0194	0.0158	0.4300
origem_movel_1_passo	passeio_aleatorio	0.0196	0.0119	0.3246
origem_movel_1_passo	sazonal_ingenuo	0.0368	0.0322	0.8782

es- quema	comparacao	DM_quad- ra- tico	DM_quad- ra- tico	veredito_quad- ratico	DM_ab- so- luto	DM_ab- so- luto	ver- dito_ab- solut- o
ori- gem_mo- vel_1_passo	ARIMA(1,1,1) 1 vs passeio_ale- atorio	- 0.0584	0.9539	nao rejeita igual	1.7074	0.1012	nao rejeita acuracia igual
ori- gem_mo- vel_1_passo	ARIMA(1,1,1) 1 vs sazo- nal_ingenuo	- 3.5586	0.0017	ARIMA superior	- 4.4149	0.0002	ARIMA superior

es- quema	comparacao	h	DM_qua- dra- tico	DM_qua- dra- tico	veredito_quadratico	DM_ab- so- luto	DM_ab- so- luto	vered- dito_ab- soluta
ori- gem_fixa_24_pas- sos	nao aplicavel	24	NA	NA	origem unica: DM nao se aplica (correcao HLN zero com $h = n$)	NA	NA	idem


As metricas devem ser comparadas sem alterar o modelo para favorecer o resultado: RMSE, MAE e MAPE menores indicam melhor desempenho. Mas a comparacao de medias e observacao, nao inferencia; por isso o teste de Diebold-Mariano, com a correcao de amostra pequena de Harvey, Leybourne e Newbold, indispensavel com um horizonte de 24 pontos. O teste e reportado apenas para o esquema de origem movel: o esquema de origem fixa tem uma unica origem, seus 24 erros formam um so caminho, e com $h = n$ a propria correcao se anula.

Contra o passeio aleatorio, o teste nao rejeita a igualdade de acuracia preditiva, sob perda quadratica e sob perda absoluta. E o resultado que a hipotese de martingale preve: se o preco de hoje ja incorpora toda a informacao disponivel, nenhum modelo linear deveria supera-lo de forma sistematica. Contra o ingenuo sazonal, o ARIMA vence com significancia, o que era esperado – nao ha razao economica para a expectativa de hoje se parecer com a de sete dias atras mais do que com a de ontem.

Uma ressalva de potencia. A janela de validacao e o trecho final da serie, justamente onde a incerteza ja foi quase toda resolvida e a variancia e minima. Os erros absolutos sao pequenos para todos os competidores, e o teste tem pouca potencia nesse regime. “Nao rejeitar” nao equivale a “sao equivalentes”.

Figura 2 -- Transformada integral de probabilidade (PIT)

Esquema 2 (um passo a frente). Sob densidades preditivas corretas, as PIT são $U(0,1)$. Faixa cinza: banda de 95% para a contagem por bin; tracejado: contagem esperada.



Fonte: elaboracao propria a partir de dados da Kalshi (snapshot congelado em data/raw/). Metodo de construcao da distribuicao implicita conforme Diercks, Katz e Wright (2026). Kolmogorov-Smirnov contra a uniforme: $D = 0,332$, $p = 0,0073$. Arcabouco de Diebold, Gunther e Tay (1998).

hori- zonte	cobertura_inter- valo_95	cober- tura_nominal	ks_es- quema1	p_ks_es- quema1	ks_es- quema2	p_ks_es- quema2
24	1	0.95	0.41	4e-04	0.3324	0.0073

A cobertura empirica do intervalo de 95 por cento e a versao fraca de uma pergunta mais exigente: a densidade preditiva inteira esta correta? A transformada integral de probabilidade responde. Sob densidades corretas as PIT seriam uniformes em $(0,1)$; o teste de Kolmogorov-Smirnov rejeita a uniformidade nos dois esquemas, e o histograma mostra concentracao central. As densidades preditivas sao largas demais – o modelo acerta o centro e exagera a incerteza, coerente com uma cobertura acima da nominal.

Os precos sao probabilidades risco-neutras, sob a medida Q , e podem incorporar premios de risco. Portanto, o confronto com o passeio aleatorio nao deve ser lido como teste isolado de eficiencia sob a medida fisica P .