

Modelagem Box-Jenkins da taxa esperada do Fed na Kalshi

Lista 01 — Econometria II

Felipe Carvalho — PPGEco/UFES

10 de setembro de 2026

1 Hipótese e enquadramento

Kagan & Baiocchi (2026) documentam que os preços da Kalshi se comportam como probabilidades genuínas, e crescentemente conforme a resolução se aproxima: na categoria *Economics*, o escore de Brier cai de forma quase linear de 0,108 (três meses) para 0,066 (fechamento), sobre 16.701 mercados resolvidos. A justificativa que oferecem é a Lei dos Grandes Números, e portanto o teste que executam é **transversal** — reúne 2,24 milhões de mercados e compara frequência realizada com preço declarado. Por construção, esse desenho nada diz sobre a **trajetória** de um mercado individual.

Este trabalho testa em série temporal, num único mercado, uma implicação de preços que se atualizam com a chegada de informação, usando Box-Jenkins. As previsões correspondentes são: a série é $I(1)$, suas diferenças são ruído branco, e nenhum ARIMA supera o passeio aleatório fora da amostra. Os artigos de referência não executam esse teste temporal; a construção da distribuição implícita segue Diercks, Katz & Wright (2026).

Desvio declarado quanto à frequência. A lista indica preferência por séries mensais ou trimestrais. A série aqui é diária: a Kalshi opera desde 2021 e seus mercados de FFR desde 2022, de modo que uma série mensal não alcançaria as 120 observações mínimas; e o fenômeno de interesse — atualização da expectativa com a chegada de informação — é intrinsecamente de alta frequência. O mínimo de 120 observações é cumprido. A série não está disponível em pacote de R ou Python.

2 Dados e reprodutibilidade

A série foi construída a partir de negócios individuais da família **KXFED**, usando os endpoints histórico e recente da API da Kalshi. O snapshot entregue, congelado em 10/09/2026, contém 64.106 negócios em 98 mercados, com hash SHA-256 de cada arquivo registrado em **manifest.json**. A transformação diária usa o último preço negociado no dia, o volume agregado e o preenchimento para a frente dos dias sem negócio. A reunião escolhida é a de maior volume total. A distribuição implícita é obtida diferenciando a função de sobrevivência dos contratos por strike, após o ajuste *middle-out* e a redistribuição de classes vazias. A Tabela 1 resume a série.

Tabela 1. Estatísticas descritivas


Série	N	Média	DP	Mín.	Mediana	Máx.	Assim.	Curt.
Nível (% a.a.)	181	3,506	0,192	2,885	3,607	3,712	−1,07	2,89
Primeira diferença (p.b.)	180	0,30	9,15	−82,40	0,00	47,19	−3,14	43,72

Contrato KXFED-26JUL, observações diárias de 30/01/2026 a 29/07/2026. DP: desvio-padrão; Assim.: assimetria; Curt.: curtose não centrada (normal = 3). p.b.: pontos-base.

3 Preparação e inspeção preliminar

3.1 Questão 1

Figura 1. Taxa esperada implícita para a reunião do FOMC de julho de 2026



Nota: Contrato KXFED-26JUL, 181 observações diárias.
Fonte: Kalshi (snapshot de 2026-09-10); cálculos do autor com o método de Diercks, Katz e Wright (2026).

A série é diária e cobre 181 observações no horizonte metodológico de 180 dias anteriores à reunião do FOMC. O horizonte ancora na data em que o mercado para de negociar (`close_time`), que é a data da reunião, e não na data de liquidação da Kalshi (`expiration_time`), uma semana posterior; as duas constam da série.

O painel A da Figura 1 mostra a trajetória da expectativa ao longo do horizonte; o painel B, suas variações diárias. A dispersão deve ser lida como função do horizonte: ela é concentrada em março, quando a incerteza sobre a reunião ainda era grande, e encolhe à medida que a data se aproxima — o que a Questão 5 quantifica. Os maiores saltos, de até 82 pontos-base num único dia, são negócios reais em livro raso, e não artefatos de construção.

A Tabela 2 sustenta uma decisão que reaparece nas Questões 2, 3 e 7: o período sazonal candidato é $s = 7$, e não $s = 5$. A Kalshi negocia nos sete dias, e o contrato analisado teve negócios em 22 dos 26 sábados e em 23 dos 26 domingos da amostra. O que distingue o fim de semana não é a

Tabela 2. Atividade de negociação por dia da semana

Dia	Negócios	Contratos (mil)	Dias na amostra	Dias com negócio	Negócios por dia
Dias úteis					
Segunda-feira	948	576,1	26	23	36,5
Terça-feira	2.214	741,7	26	24	85,2
Quarta-feira	1.952	540,0	26	26	75,1
Quinta-feira	899	374,8	25	24	36,0
Sexta-feira	1.097	797,7	26	25	42,2
Fim de semana					
Sábado	542	109,4	26	22	20,8
Domingo	698	113,1	26	23	26,8

Negócios do contrato analisado dentro da janela da série. Negócios por dia: total dividido pelos dias de calendário do mesmo tipo na amostra.

ausência de negociação, e sim a espessura do livro: o volume diário cai por um fator de três a sete. Nenhuma observação é, portanto, mero carregamento do último preço de sexta-feira, e o calendário relevante tem sete dias.

4 Ordem de integração

4.1 Questão 2

Os testes ADF, PP e KPSS foram calculados com as especificações sem termos determinísticos, com constante e com constante e tendência (Tabela 3). No ADF, a defasagem é escolhida pelo AIC a partir de um máximo de 12; PP e KPSS usam a janela curta de Bartlett. As hipóteses nulas diferem: ADF e PP testam a raiz unitária, o KPSS testa a estacionariedade, e as estrelas indicam rejeição da respectiva nula.

Em nível, a evidência é mista, e convém dizê-lo em vez de escolher o teste que convém. O KPSS rejeita a estacionariedade com folga nas duas especificações, e o ADF sem termos determinísticos e com tendência não rejeita a raiz unitária. Mas o ADF com constante e o PP com tendência a rejeitam. A ambiguidade tem causa identificável: a série muda de regime no meio da amostra — dispersa até março, quase parada depois (Figura 1) —, e testes de raiz unitária sabidamente perdem tamanho e potência sob quebra na variância. Na primeira diferença, ao contrário, os seis testes concordam: ADF e PP rejeitam a raiz unitária em todas as especificações e o KPSS deixa de rejeitar a estacionariedade. A decisão é $d = 1$, que é também o que a hipótese de martingale prevê; diferenciar uma série que fosse estacionária em nível apareceria como raiz MA unitária na Questão 6, e ela aparece apenas quando se diferencia uma segunda vez.

$D = 0$ é resultado, não omissão (Tabela 4). Com $s = 7$ justificado pela atividade de negociação, cinco evidências independentes convergem: os testes de raiz unitária sazonal OCSB e Canova-Hansen indicam $D = 0$; a FAC da primeira diferença fica dentro da banda de 95% nos lags 7, 14 e 21; e impor $D = 1$ piora o AIC e o BIC em cerca de 112 pontos. Diferenciar sazonalmente uma série sem raiz sazonal introduz uma raiz MA não-invertível, exatamente o defeito que a Questão 6 examina.

Tabela 3. Testes de raiz unitária

Teste	Termos determinísticos	Estatística	Valores críticos			Defasagens
			10%	5%	1%	
Nível						
ADF	Sem constante	2,891	−1,62	−1,95	−2,58	11
ADF	Constante	−3,658***	−2,57	−2,88	−3,46	11
ADF	Constante e tendência	−2,157	−3,13	−3,43	−3,99	11
PP	Constante	−2,899**	−2,58	−2,88	−3,47	4
PP	Constante e tendência	−6,633***	−3,14	−3,44	−4,01	4
KPSS	Constante	3,068***	0,35	0,46	0,74	4
KPSS	Constante e tendência	0,641***	0,12	0,15	0,22	4
Primeira diferença						
ADF	Sem constante	−8,341***	−1,62	−1,95	−2,58	7
ADF	Constante	−7,255***	−2,57	−2,88	−3,46	10
ADF	Constante e tendência	−7,935***	−3,13	−3,43	−3,99	10
PP	Constante	−22,336***	−2,58	−2,88	−3,47	4
PP	Constante e tendência	−22,347***	−3,14	−3,44	−4,01	4
KPSS	Constante	0,047	0,35	0,46	0,74	4
KPSS	Constante e tendência	0,013	0,12	0,15	0,22	4

ADF e PP: H_0 de raiz unitária, rejeitada quando a estatística fica abaixo do valor crítico. KPSS: H_0 de estacionariedade, rejeitada quando fica acima. *, ** e *** indicam rejeição de H_0 a 10%, 5% e 1%. Defasagens: no ADF, a escolhida pelo AIC, com máximo de 12; no PP e no KPSS, a janela curta de Bartlett.

Tabela 4. Evidência sobre a diferença sazonal

Evidência	Valor	Indica
OCSB: diferenças sazonais sugeridas	0	$D = 0$
Canova-Hansen: diferenças sazonais sugeridas	0	$D = 0$
FAC da primeira diferença, lag 7	0,115	Dentro da banda
FAC da primeira diferença, lag 14	0,000	Dentro da banda
FAC da primeira diferença, lag 21	0,056	Dentro da banda
$AIC(D = 0) - AIC(D = 1)$	-112,0	$D = 0$
$BIC(D = 0) - BIC(D = 1)$	-111,9	$D = 0$

Período sazonal $s = 7$. Banda de 95% da FAC: $\pm 0,146$. Nos critérios de informação, valor negativo favorece $D = 0$.

Tabela 5. Modelos candidatos


Modelo	Leitura	Evidência na FAC/FACP
ARIMA(0,1,1)	Leitura canônica: a FAC corta após o lag 1 e a FACP decai. É a especificação que o par de gráficos indica primeiro.	FAC significativa nos lags 1, 4, 8; FACP decai ao longo de 1, 2, 3, 5, 6, 8.
ARIMA(1,1,0)	Leitura AR concorrente: o lag 1 da FACP é o maior em módulo; testa se a persistência se explica por um único termo autorregressivo.	FACP no lag 1 = $-0,3175$, fora da banda de 95% ($\pm 0,1461$).
ARIMA(1,1,1)	Mistura parcimoniosa: acomoda simultaneamente persistência e choque quando FAC e FACP não separam com nitidez.	FAC no lag 1 = $-0,3175$ e FACP no lag 1 = $-0,3175$, ambas fora da banda.
ARIMA(3,1,3)	Especificação estendida, incluída para ser testada contra a restrição de admissibilidade da Q4(f): os lags 2, 3, 5, 6 e 8 da FACP sugerem estrutura mais rica, e o AIC tende a premiá-la.	FACP fora da banda também nos lags 2, 3, 5, 6, 8.

Nenhum candidato tem componente sazonal ($P = D = Q = 0$, $s = 7$).

5 Identificação

5.1 Questão 3

Figura 2. Funções de autocorrelação e de autocorrelação parcial da primeira diferença



Nota: Primeira diferença da série. Faixa sombreada: banda de 95% ($\pm 1,96/\sqrt{n}$); em azul, as defasagens fora dela. Linhas verticais finas: múltiplos do período sazonal de 7 dias.
Fonte: Kalshi (snapshot de 2026-09-10); cálculos do autor com o método de Diercks, Katz e Wright (2026).

A FAC da primeira diferença corta abruptamente após o lag 1, com um coeficiente negativo e forte, enquanto a FACP decai ao longo de vários lags (Figura 2). Esse par de padrões identifica um MA(1); o lag 1 isolado da FACP sustenta a leitura AR(1) concorrente. O coeficiente negativo no primeiro lag é o que a literatura de microestrutura atribui à oscilação entre as pontas de compra e de venda, e não à previsibilidade econômica.

Daí os candidatos da Tabela 5: ARIMA(0,1,1), a leitura canônica; ARIMA(1,1,0), a leitura autorregressiva; ARIMA(1,1,1), a mistura parcimoniosa. O ARIMA(3,1,3) entra como quarta

Tabela 6. Autocorrelações nas defasagens sazonais e vizinhas

Defasagem	Tipo	FAC	FACP
6	Vizinha	-0,062	-0,204
7	Sazonal	0,115	-0,036
8	Vizinha	-0,147	-0,292
13	Vizinha	-0,004	-0,071
14	Sazonal	0,000	-0,013
15	Vizinha	0,038	0,130
20	Vizinha	0,015	0,006
21	Sazonal	0,056	0,046
22	Vizinha	-0,012	-0,007

Primeira diferença da série. Banda de 95%: $\pm 0,146$. Em negrito, valores fora da banda. Nenhuma defasagem sazonal (7, 14, 21) é significativa.

especificação, deliberadamente estendida, para ser confrontada com a restrição de admissibilidade da Questão 4 — os lags 2, 3, 5, 6 e 8 da FACP sugerem estrutura mais rica, e é útil verificar o que acontece quando o critério de informação a premia. Todos usam a mesma variável dependente e a mesma amostra efetiva, condição sem a qual a comparação por AIC e BIC não seria válida.


As defasagens sazonais foram inspecionadas explicitamente: seis ciclos completos na Figura 2 e, na Tabela 6, os lags 7, 14 e 21 com suas vizinhanças. Nenhuma defasagem sazonal fica fora da banda de 95%. Por isso nenhum candidato leva componente sazonal: a ausência de sazonalidade é uma conclusão apoiada em evidência.

6 Estimação e seleção

6.1 Questão 4

Os modelos foram estimados por máxima verossimilhança sobre a mesma amostra efetiva ($n = 180$ após a diferenciação), o que torna AIC e BIC comparáveis entre as colunas da Tabela 7.

Figura 3. Raízes inversas dos polinômios AR e MA



Nota: Raízes inversas dos polinômios AR (círculos) e MA (triângulos). É admissível a raiz inversa dentro do círculo unitário, com folga de 0,001.

Fonte: Kalshi (snapshot de 2026-09-10); cálculos do autor com o método de Diercks, Katz e Wright (2026).

Tabela 7. Estimaco dos modelos candidatos

	ARIMA(0,1,1)	ARIMA(1,1,0)	ARIMA(1,1,1)	ARIMA(3,1,3)
ϕ_1		−0,314*** (0,071)	0,250*** (0,087)	−0,953*** (0,090)
ϕ_2				−0,676*** (0,108)
ϕ_3				0,090 (0,089)
θ_1	−0,731*** (0,062)		−0,821*** (0,042)	0,480*** (0,056)
θ_2				−0,029 (0,065)
θ_3				−0,802*** (0,057)
$\hat{\sigma}_a^2 \times 10^3$	6,475	7,547	6,234	5,596
Log-verossimilhana	198,29	184,84	202,24	211,42
AIC	−392,58	−365,68	−398,47	−408,83
BIC	−386,20	−359,30	−388,89	−386,48
Observaces	180	180	180	180
Admissvel (Q4f)	Sim	Sim	Sim	No
Selecionado			Sim	

Erros-padro entre parnteses. *, ** e *** indicam significncia a 10%, 5% e 1%, respectivamente.

Admissvel: todas as razes AR e MA com mdulo maior que $1 + 0,001$. A seleo aplica o AIC apenas entre os admissveis.

Tabela 8. Raízes dos polinômios característicos

Polinômio	Parte real	Parte imaginária	Módulo	Admissível
ARIMA(0,1,1)				
MA	1,368	0,000	1,367671	Sim
ARIMA(1,1,0)				
AR	-3,181	0,000	3,181204	Sim
ARIMA(1,1,1)				
AR	4,002	0,000	4,001659	Sim
MA	1,217	0,000	1,217387	Sim
ARIMA(3,1,3)				
AR	-0,669	0,899	1,120705	Sim
AR	-0,669	-0,899	1,120705	Sim
AR	8,875	0,000	8,875448	Sim
MA	1,246	0,000	1,246451	Sim
MA	-0,641	0,767	1,000034	Não
MA	-0,641	-0,767	1,000034	Não

Raízes dos polinômios $\phi(z)$ e $\theta(z)$ (não as inversas). Condição de estacionariedade e de invertibilidade: módulo maior que 1. Seis casas decimais para tornar visível a distância das raízes MA do ARIMA(3,1,3) ao círculo unitário; em negrito, as raízes inadmissíveis.

Tabela 9. Modelo escolhido por critério, com e sem a restrição de admissibilidade

Critério	Todos os candidatos	Apenas admissíveis
AIC	ARIMA(3,1,3)	ARIMA(1,1,1)
BIC	ARIMA(1,1,1)	ARIMA(1,1,1)

4 candidatos, 3 admissíveis. Sem a restrição, o AIC elegeeria um modelo não-invertível; entre os admissíveis, AIC e BIC concordam. Modelo levado adiante: ARIMA(1,1,1).

Raízes e admissibilidade. A Tabela 8 reporta as raízes propriamente ditas, para as quais a condição de estacionariedade e de invertibilidade é módulo maior que um. A Figura 3 desenha as inversas contra o círculo unitário, convenção gráfica usual: é admissível o ponto que cai dentro do círculo. O ARIMA(3,1,3) tem duas raízes MA de módulo 1,000034. Não se trata de uma margem apertada, e sim de raízes numericamente sobre o círculo unitário: o otimizador parou na fronteira da região admissível, não dentro dela. O polinômio não é invertível e o modelo está fora de competição.

Ordem das operações. Invertibilidade e estacionariedade são restrições de admissibilidade, não critérios de ajuste. Um modelo que as viola não é um modelo pior; é um modelo que não está no conjunto de escolha. Por isso o filtro se aplica antes do critério de informação, e não como ressalva posterior. A Tabela 9 mostra a consequência: sem a restrição, o AIC elegeeria o ARIMA(3,1,3) — o melhor ajuste entre os candidatos e, simultaneamente, o único inadmissível. Entre os três admissíveis, AIC e BIC concordam no ARIMA(1,1,1), que é o modelo levado adiante. Relatar apenas o vencedor do AIC irrestrito produziria um modelo cuja representação


autorregressiva infinita não existe.

Convenção de k . A contagem de parâmetros usada pelos critérios de informação foi verificada no próprio objeto ajustado, e não presumida: `attr(logLik(fit), "df")` devolve 3 para um modelo com 2 coeficientes, de modo que a variância residual estimada conta como parâmetro livre. O AIC recalculado à mão com essa convenção reproduz exatamente o valor reportado (`output/tables/q4_convencao_k.csv`).

7 Diagnóstico

7.1 Questão 5

Figura 4. Diagnóstico dos resíduos do modelo selecionado



Nota: Resíduos do ARIMA(1,1,1). Em B, faixa sombreada: banda de 95%; em azul, defasagens fora da banda. Em C e D, a curva e a reta vermelhas são a referência normal.
Fonte: Kalshi (snapshot de 2026-09-10); cálculos do autor com o método de Diercks, Katz e Wright (2026).

O Ljung-Box, calculado no lag 14 com correção pelos graus de liberdade do modelo, não rejeita a ausência de autocorrelação residual (Tabela 10), o que a FAC do painel B da Figura 4 confirma. O Jarque-Bera rejeita a normalidade com folga, resultado esperado numa série cujas variações se concentram em poucos dias de notícia — os painéis C e D mostram o pico central e as caudas pesadas.

Heterocedasticidade: dois fenômenos distintos. O ARCH-LM testa agrupamento de volatilidade, isto é, variância alta seguida de variância alta. Não é o que caracteriza esta série. A dispersão aqui cai porque o horizonte encurta: a cada dia que passa, resta menos incerteza a ser resolvida até a reunião. Isso é uma tendência determinística na variância, e um teste desenhado para agrupamento pode não detectá-la ainda que ela seja grande. Por isso o ARCH-LM aparece

Tabela 10. Testes de diagnóstico

Teste	Estatística	Distribuição	p-valor
Resíduos do modelo selecionado			
Ljung-Box, 14 defasagens	19,22	χ^2_{12}	0,083
Jarque-Bera	10.702,26	χ^2_2	< 0,001
ARCH-LM, 7 defasagens	22,07	χ^2_7	0,002
Variância determinística no horizonte			
Inclinação de $\log(\Delta y_t^2)$ nos dias até a reunião	5,89	t	< 0,001
Razão de variâncias, 1. ^a metade / 2. ^a metade	55,63	F	< 0,001

Ljung-Box com graus de liberdade corrigidos pelo número de coeficientes estimados. Jarque-Bera: H_0 de normalidade. ARCH-LM: H_0 de ausência de agrupamento de volatilidade.

Inclinação estimada: 0,0224 (erro-padrão 0,0038), em log-pontos por dia de horizonte; positiva significa dispersão maior longe da reunião. As diferenças nulas saem da regressão por causa do logaritmo.


acompanhado de duas medidas diretas, no segundo painel da Tabela 10: a regressão do logaritmo da diferença ao quadrado sobre os dias que faltam para a reunião tem inclinação positiva e altamente significativa, e a variância da primeira metade da amostra supera a da segunda por um fator de 55,6. Os três resultados são complementares, e não substitutos.

Modelos descartados. O sobreajuste deliberado da Tabela 11 acrescenta um termo AR e um termo MA ao modelo selecionado; nenhum dos termos adicionais é significativo e nenhum dos dois modelos reduz o AIC, de modo que a especificação escolhida é adequada nesse sentido. A Tabela 12 registra o caminho percorrido, e não apenas o destino: o ARIMA(3,1,3) sai por falha de invertibilidade na Questão 4, e as duas especificações de sobreajuste saem por não melhorarem o ajuste.

8 Sobrediferenciação

8.1 Questão 6

Figura 5. Autocorrelação dos resíduos: modelo selecionado e sobrediferenciado



Nota: FAC dos resíduos; faixa sombreada: banda de 95%; em azul, defasagens fora dela. No modelo sobrediferenciado, $\theta = -1,0000$: a raiz MA cai sobre o círculo unitário, e a variância residual sobe 22%.

Fonte: Kalshi (snapshot de 2026-09-10); cálculos do autor com o método de Diercks, Katz e Wright (2026).

Tabela 11. Sobreajuste deliberado

	ARIMA(1,1,1)	ARIMA(2,1,1)	ARIMA(1,1,2)
ϕ_1	0,250*** (0,087)	0,244*** (0,089)	0,055 (0,244)
ϕ_2		-0,088 (0,081)	
θ_1	-0,821*** (0,042)	-0,798*** (0,053)	-0,613*** (0,234)
θ_2			-0,162 (0,175)
$\hat{\sigma}_a^2 \times 10^3$	6,234	6,228	6,244
Log-verossimilhança	202,24	202,80	202,59
AIC	-398,47	-397,61	-397,18
BIC	-388,89	-384,83	-384,40
Observações	180	180	180

Erros-padrão entre parênteses. *, ** e *** indicam significância a 10%, 5% e 1%, respectivamente.

Sobreajuste deliberado: um termo AR e um termo MA a mais que o modelo selecionado (primeira coluna). Nenhum dos termos adicionais é significativo e nenhum dos dois modelos reduz o AIC.

Tabela 12. Modelos descartados

Modelo	Etapas	Motivo	Evidência
ARIMA(3,1,3)	Q4(f)	Polinômio MA não-invertível	raízes MA com módulo 1,000034; 1,000034 (limiar $1 + 0,001$)
ARIMA(2,1,1)	Q5(e)	Termo extra não melhora o ajuste	AIC -397,6060 contra -398,4714 do ARIMA(1,1,1) (diferença +0,8653); admissível: sim
ARIMA(1,1,2)	Q5(e)	Termo extra não melhora o ajuste	AIC -397,1758 contra -398,4714 do ARIMA(1,1,1) (diferença +1,2956); admissível: sim

Tabela 13. Modelo selecionado e sua versão sobrediferenciada

	Selecionado	Sobrediferenciado
ϕ_1	0,250*** (0,087)	-0,312*** (0,071)
θ_1	-0,821*** (0,042)	-1,000*** (0,015)
$\hat{\sigma}_a^2 \times 10^3$	6,234	7,616
Log-verossimilhança	202,24	180,64
AIC	-398,47	-355,28
BIC	-388,89	-345,72
Observações	180	179
Módulo da raiz MA	1,2174	1,000001

Erros-padrão entre parênteses. *, ** e *** indicam significância a 10%, 5% e 1%, respectivamente.

O sobrediferenciado aumenta d em uma unidade e mantém p e q . Seu $\hat{\theta}_1$ encosta em -1 e a raiz MA cai sobre o círculo unitário: é a assinatura da sobrediferenciação. AIC e BIC não são comparáveis entre as colunas, porque a variável dependente difere (Δy contra $\Delta^2 y$) e a amostra efetiva perde uma observação.

O modelo sobrediferenciado aumenta d em uma unidade e mantém os demais termos do modelo selecionado. Os sinais práticos aparecem juntos na Tabela 13: o coeficiente MA vai a -1 , a raiz do polinômio MA cai sobre o círculo unitário e a variância residual aumenta. A Figura 5 mostra o terceiro sinal: surge autocorrelação negativa significativa nos resíduos, que o modelo corretamente diferenciado não tem.

9 Previsão fora da amostra

9.1 Questão 7


As últimas 24 observações foram reservadas para validação. O primeiro esquema usa origem fixa e previsão de múltiplos passos; o segundo usa origem móvel e previsão de um passo, com os coeficientes mantidos. Os benchmarks são o passeio aleatório e o ingênuo sazonal, este com período $s = 7$ — o período justificado na Questão 1 pela atividade de negociação nos sete dias da semana, e confirmado como sem raiz sazonal na Questão 2.

Tabela 14. Erros de previsão na janela de validação

Modelo	REQM (p.b.)	EAM (p.b.)	EAPM (%)
Esquema 1: origem fixa, 1 a 24 passos			
ARIMA(1,1,1)	2,34	2,06	0,561
Passeio aleatório	2,82	2,44	0,665
Sazonal ingênuo ($s = 7$)	2,41	2,08	0,568
Esquema 2: origem móvel, 1 passo			
ARIMA(1,1,1)	1,94	1,58	0,430
Passeio aleatório	1,96	1,19	0,325
Sazonal ingênuo ($s = 7$)	3,68	3,22	0,878

Janela de validação: últimas 24 observações. Em negrito, o menor erro de cada esquema. REQM: raiz do erro quadrático médio; EAM: erro absoluto médio; EAPM: erro absoluto percentual médio. Esquema 2 mantém fixos os coeficientes estimados até a origem.

Figura 6. Previsão fora da amostra contra os benchmarks



Nota: Esquema 1: origem fixa em 05/07/2026, previsões de 1 a 24 passos. Faixa sombreada: intervalo de previsão de 95%, cuja cobertura empírica foi de 100,0%.

Fonte: Kalshi (snapshot de 2026-09-10); cálculos do autor com o método de Diercks, Katz e Wright (2026).


As métricas da Tabela 14 devem ser comparadas sem alterar o modelo para favorecer o resultado. Mas a comparação de médias é observação, não inferência; por isso o teste de Diebold-Mariano da Tabela 15, com a correção de amostra pequena de Harvey, Leybourne e Newbold, indispensável com um horizonte de 24 pontos.

Tabela 15. Testes de Diebold-Mariano

Contra	Perda quadrática		Perda absoluta	
	DM	p-valor	DM	p-valor
Passeio aleatório	-0,058	0,954	1,707	0,101
Sazonal ingênuo ($s = 7$)	-3,559	0,002	-4,415	< 0,001

Esquema 2 (um passo, origem móvel). Estatística de Diebold e Mariano com a correção de Harvey, Leybourne e Newbold e referência t_{n-1} . H_0 : acurácia igual. Valor negativo favorece o ARIMA. O Esquema 1 não recebe o teste: tem uma única origem, e com $h = n = 24$ a correção se anula.

Figura 7. Diferencial de perda acumulado contra o passeio aleatório



Nota: Erro quadrático do ARIMA(1,1,1) menos o do passeio aleatório, acumulado ao longo da janela de validação. Abaixo de zero, o modelo acumula vantagem; acima, o benchmark.
 Fonte: Kalshi (snapshot de 2026-09-10); cálculos do autor com o método de Diercks, Katz e Wright (2026).

Contra o passeio aleatório, o teste não rejeita a igualdade de acurácia preditiva, sob perda quadrática e sob perda absoluta. É o resultado que a hipótese de martingale prevê: se o preço de hoje já incorpora toda a informação disponível, nenhum modelo linear deveria superá-lo de forma sistemática. A Figura 7 mostra onde a diferença se acumula ao longo da janela. Contra o ingênuo sazonal, o ARIMA vence com significância, o que era esperado — não há razão econômica para a expectativa de hoje se parecer com a de sete dias atrás mais do que com a de ontem.


Uma ressalva de potência. A janela de validação é o trecho final da série, justamente onde a incerteza já foi quase toda resolvida e a variância é mínima. Os erros absolutos são pequenos para todos os competidores, e o teste tem pouca potência nesse regime. “Não rejeitar” não equivale a “são equivalentes”.

Tabela 16. Calibração das densidades preditivas

Medida	Valor	p-valor
Cobertura empírica do intervalo de 95%	100,0%	—
KS da PIT, Esquema 1	0,410	< 0,001
KS da PIT, Esquema 2	0,332	0,007

KS: Kolmogorov-Smirnov das PIT contra a uniforme; rejeitar indica densidade preditiva mal calibrada (Diebold, Gunther e Tay, 1998).

Figura 8. Transformada integral de probabilidade, Esquema 2



Nota: Esquema 2 (um passo à frente). Sob densidades preditivas corretas, as PIT são $U(0,1)$. Faixa cinza: banda de 95% para a contagem por classe; linha: contagem esperada. Kolmogorov-Smirnov contra a uniforme: $D = 0,332$, $p = 0,0073$.
Fonte: Kalsnii (snapshot de 2026-09-10); cálculos do autor com o método de Diercks, Katz e Wright (2026).

A cobertura empírica do intervalo de 95% é a versão fraca de uma pergunta mais exigente: a densidade preditiva inteira está correta? A transformada integral de probabilidade responde (Figura 8). Sob densidades corretas as PIT seriam uniformes em $(0,1)$; o teste de Kolmogorov-Smirnov rejeita a uniformidade nos dois esquemas (Tabela 16), e o histograma mostra concentração central. As densidades preditivas são largas demais — o modelo acerta o centro e exagera a incerteza, coerente com uma cobertura acima da nominal. A razão é a mesma da ressalva de potência: o modelo foi estimado numa amostra que inclui a turbulência de março, e sua variância residual é grande demais para o trecho calmo em que é avaliado.

Os preços são probabilidades risco-neutras, sob a medida Q , e podem incorporar prêmios de risco. Portanto, o confronto com o passeio aleatório não deve ser lido como teste isolado de eficiência sob a medida física P .